Künstliche neuronale Netzwerke und Tensorflow

Hubl Lukas, Grüneis Dominik

Agenda

- Installation von Tensorflow
- Theorie zu künstliche neurale Netwerke
- Anwenden von Tensorflow mit MNIST

Installation

Installation

- python3: ausführen der Installationsdatei
- pandas: pip install pandas
- matplotlib: pip install matplotlib
- tensorflow:
 - O MAC: pip install tensorflow-1.7.0rc1-py3-none-any.whl
 - O WIN: pip install tensorflow-1.7.0rc1-cp36-cp36m-win_amd64.whl
 - O **Ubuntu:** pip install tensorflow-1.7.0rc1-cp36-cp36m-linux_x86_64.whl
 - O Generell: pip install tensorflow





Setup check

Python 3.5.6

Befehl: "python3" bzw. python

Ausgabe:

```
[Lukass-MacBook-Pro:Workshop relevant lukashubl$ python3
Python 3.6.4 |Anaconda, Inc.| (default, Jan 16 2018, 12:04:33)
[GCC 4.2.1 Compatible Clang 4.0.1 (tags/RELEASE_401/final)] on darwin
Type "help", "copyright", "credits" or "license" for more information.
>>>
```

Bei Problemen hilft ihnen Herr Hubl gerne weiter

TensorFlow

Download: https://github.com/lukashubl/ann_tf_ws/blob/master/setupCheck.py

Befehl: "python3 setupCheck.py"

Ausgabe: Skript wird dir sagen ob alles passt

MacOS, Windows & Linux

Theorie

Grundlagen

Was sind künstliche neuronale Netzwerke?


Warum möchten wir KNNs verwenden?

Wie entwickeln wir KNNs?





Vergleich


Mensch vs Computer




Einfacher Predictor










х	у	Тур
1	3	Regenwurm
3	1	Raupe

y=Ax

y=0.25x

y=(0.25)*(3.0)=0.75

error=(korrektes Ergebnis - Funktionsergebnis) E=1.1 - 0.75 = 0.35



y=Ax

targetY= $(A+\Delta A)x$

targetY-actualY= $(A+\Delta A)x$ -Ax


E=targetY-actualY

 $E=Ax+(\Delta A)x -Ax$

 $E=(\Delta A)x$

 $\Delta A = E/x$

X	у	Тур
1	3	Regenwurm
3	1	Raupe



$$\Delta A = E / x$$

$$\Delta A = 0.35/3 = 0.1167$$


$$y = 0.3667x$$

$$y = 0.3667 * 1.0 = 0.3667$$

$$E = 2.9 - 0.3667 = 2.5333$$

$$\Delta A = 2.5333 / 1.0 = 2.5333$$

$$y = 2.9x$$



X	y	Тур
1	3	Regenwurm
3	1	Raupe

Learning rate L

$$\Delta A = (E / x) L$$

$$L = 0.5$$

$$\Delta A = (0.35 / 3) 0.5 = 0.0583$$

$$y = 0.3083x$$


$$y = 0.3083 * 1.0 = 0.3083 -> E = 2.5917$$


$$\Delta A = (2.5917 / 1.0) * 0.5 = 1.2958$$


$$y = 2.9x$$

Biologisches neuronales Netwerk

- Dendriten = Empfangseinheit
- Axon = Sendeeinheit
- Zellkern = Entscheidungseinheit
- Threshold muss überschritten werden
 -> Signal am Axon
- Axon über Synapsen verbindung zu anderen Neuronen










Künstliches neuronales Netwerk

- Gewichtete Inputs = Dendriten
- Aktivierungsfunktion = Threshold
- Ausgang = Axon
- Gewichtete Inputs werden summiert und dann an eine Aktivierungsfunktion gesendet







Einfaches KNN


- Jede Node mit Node in nächster Layer verbunden
- Ermöglicht einfache Matrixmultiplikation
- Signal wird durchgepasst

$$X_{hidden} = W_{input_hidden} \cdot I$$

$$X_{hidden} = \begin{pmatrix} 0.9 & 0.3 & 0.4 \\ 0.2 & 0.8 & 0.2 \\ 0.1 & 0.5 & 0.6 \end{pmatrix} \cdot \begin{pmatrix} 0.9 \\ 0.2 \\ 0.1 \end{pmatrix}$$

$$X_{hidden} = \begin{pmatrix} 1.16 \\ 0.42 \\ 0.62 \end{pmatrix}$$

$$O_{hidden} = sigmoid \begin{pmatrix} 1.16 \\ 0.42 \\ 0.62 \end{pmatrix} = \begin{pmatrix} 0.761 \\ 0.603 \\ 0.650 \end{pmatrix}$$




w 1,1	w 1,2	w 1,3
w 2,1	w 2,2	w 2,3
w 3,1	w 3,2	w 3,3

0.9	0.3	0.4
0.2	0.8	0.2
0.1	0.5	0.6

Inputs
0.9
0.1
0.8


Einfaches KNN

- Fehler Backpropagation
- Aufteilung des Fehler je nach gewichtung
- Summieren der Fehler
- Zurückpropagieren des Fehlers auf den nächsten Layer
- Vereinfacht uns Tensorflow



Updaten der Gewichte

- Kompliziertester Teil
- Schritt f
 ür Schritt
- Berechnung über die Steigung Δ
- Vereinfacht uns Tensorflow



$$\frac{\delta E}{\delta w_{jk}} = -(t_k - O_k) \cdot afunc(\sum w_{jk} \cdot O_j)(1 - afunc(\sum w_{jk} \cdot o_j)) \cdot o_j$$

$$w_{jk\,neu} = w_{jk\,old} - \alpha \cdot \frac{\delta E}{\delta w_{jk}}$$

$$\Delta w_{jk} = \alpha \cdot E_k \cdot O_k (1 - O_k) \cdot O_j^T$$

Tensorflow-Workshop

Agenda

Kennenlernen und verwenden von MNIST


Erstellen des Models

Festlegen des Bewertungsschemas

Das Model trainieren

Evaluieren der Ergebnisse

Visualisieren und wiederverwenden des Models



MNIST Klassifizierung in TensorFlow

MNIST

Model

Bewertungsschema

Iraining

Evaluieren & Visualisierei

/erwenden in Realtime

MNIST

- Was ist MNIST
- Aufbau der Daten
- Code


MNIST Datenbank

- Modified Institute of Standards and Technology Warum sind Test- und Trainings-Datensätze getrennBilder von handschriftlichen Ziffern
 - 60.000 Trainings-Datensätze
 - 10.000 Test-Datensätze



MNIST Datenbank

- Bitmap
- 28 x 28 Pixel
- Pixelwert zwischen 0 1
- Jedes Bild hat dazugehöriges Label



Coding time

MNIST Klassifizierung in TensorFlow


MNIST Model Bewertungsschema Training Evaluieren & Visualisieren Verwenden in Realtime

Modell


- Aufgabe des Models
- Softmax
- Code


Model

- liefert Output zu Input
- muss trainiert werden
- Logistic Regression
- Softmax Regression



Model





Logistic Regression


Softmax Regression




Was ist der grundlegende Unterschied zwischen den beiden Modellen?



Model





Logistic Regression

Softmax Regression

Coding time

MNIST Klassifizierung in TensorFlow

MNIST Model Bewertungsschema Training Evaluieren & Visualisieren Verwenden in Realtime

Bewertungsschema

- Größe die es zu optimieren gilt
- Cross-Entropy
- Code

Bewertungsschema

- Wie k\u00f6nnen die Gewichte optimiert werden?
- Welche Größe ist ausschlaggebend?
- Notwendig um zu lernen
- Cross-Entropy



Cross-Entropy

- Unterschied zwischen der echten Verteilungsfunktion und jener des Models
- Cross-Entropy als ausschlaggebende Größe
- Wird dieser Wert minimiert entspricht Prediction dem Label → Ergebnis ist korrekt

Rechenbeispiel: Zahl 7

MNIST Klassifizierung in TensorFlow

MNIST Model Bewertungsschema Training Evaluieren & Visualisieren Verwenden in Realtime

Training

- Gradient Descent
- Parameter
- Code

Training

Bereits geschafft:

- Daten laden
- Model erstellt
- Bewerten der Ergebnisse


Nächster Schritt:

 Verbessern des Models durch Training



Gradient Descent

- Bergsteiger-Beispiel
- Berg → Fehlerfunktion (Cross-Entropy)
- Position des Bergsteigers → Fehler
- Schritt Bergab → Lernschritt



Initiale Gewichte


Was wird dadurch bestimmt?

- Startposition des Bergsteigers
- Initiale Fehler welchen es zu optimieren gilt



Lernrate


- Bestimmt wie "schnell" gelernt wird
- Die Größe der Schritte des Bergsteigers




Lernrate

Was passiert wenn die Lernrate

- zu groß ist?
- zu klein ist?





MNIST Klassifizierung in TensorFlow

MNIST Model Bewertungsschema Training Evaluieren & Visualisieren Verwenden in Realtime

Evaluieren

- Accuracy
- TensorBoard
- Code


Evaluieren

- Accuracy
- Wie viele Datensätze werden richtig klassifiziert



TensorBoard

- Visualisierungen aller Art
- Graph
- Skalare
- Projektor



MNIST Klassifizierung in TensorFlow


MNIST Model Bewertungsschema Training Evaluieren & Visualisieren Verwenden in Realtime

Verwenden des Models in Realtime-Anwendung

- Model speichern
- Model wiederverwenden
- Code


Vielen Dank für ihre Aufmerksamkeit


Fun Facts





Was ist das?


Ratespiel





















Ratespiel



Wirklich vielen Dank für ihre Aufmerksamkeit